

SkillNet A/B/C 路由对比实验执行指南

第一轮运行准备、规模实验修订与父 Skill 扩展设计

基于 21 条 V4 Gold Tasks、46 个原子 Skills、Gold-only 确定性评价器

覆盖：完整主实验、10/30/46 规模实验、精确/模糊描述、相邻 Skill 干扰、约束与复杂度分析、No-Tool 分析，以及父 Skill 独立扩展实验

版本：Run Guide v1.1

修订日期：2026-07-29

核心修订：E1 任务与 10-Skill 集合；Configuration C 裁剪方案；S3 父 Skill 独立扩展

本文件用于正式跑实验前的操作冻结（experiment freeze）、运行记录与结果解释。

目录

1 本指南的定位与已冻结结论	3
2 数据与文件基础	3
2.1 当前任务与 Gold 结构	3
2.2 46 个原子 Skills 的部门分布	4
3 三种 Configuration 的实验定义	4
3.1 Configuration A: Flat Catalogue (基线)	4
3.2 Configuration B: Department-grouped Catalogue	4
3.3 Configuration C: Graph-structured Catalogue	4
3.4 规模条件下 C 的闭合子图	5
3.5 三种配置必须保持不变的控制变量	5
4 实验总览与运行数量	6
5 E0: 完整 46-Skill A/B/C 主实验	6
5.1 目的与运行量	6
5.2 主要指标	6
5.3 结果解释	7
6 E1: 规模扩展实验 ($10 \subset 30 \subset 46$)	7
6.1 目的	7
6.2 固定 5 条任务 (修订版)	7
6.3 10-Skill 环境	7
6.3.1 覆盖核对	8
6.4 30-Skill 环境	8
6.5 46-Skill 环境	8
6.6 如何构造 A/B/C 的三个规模版本	8
6.7 运行量与指标	9
7 E2: 约束任务分析 (复用 E0, 不重新运行)	9
8 E3: 任务复杂度与组织方式分析 (复用 E0)	9
8.1 按现有任务类别分组	9
8.2 按 Gold 路径长度分组	9
8.3 按必要部门数量分组	10
9 E4: 精确描述与模糊描述	10
10 S1: 相邻 Skill 边界干扰实验 (可选补充)	10

11 S2: No-Tool Detection (复用 E0)	10
12 S3: 父 Skill 识别与原子步骤展开 (独立扩展)	10
12.1 为什么作为独立扩展	10
12.2 父 Skill 的定义	11
12.3 A/B/C 在扩展实验中的输入	11
12.4 任务与运行量	11
12.5 评价器需要的小型扩展	11
13 评价指标与当前 Python 实现对照	12
14 真实运行流程	13
14.1 运行前冻结清单	13
14.2 单条任务运行规则	13
14.3 建议保存目录	13
15 第一轮跑一次与三次重复的区别	13
15.1 第一轮先跑一次	13
15.2 时间充裕时跑三次	14
16 结果解读与避免误判	14
17 下一步开始跑之前的待办清单	14
A Run Guide v1.1 相对 v1.0 的修订	15
B 配套可下载文件	15

1 本指南的定位与已冻结结论

本项目比较三种 Skill 组织方式在同一批企业路由任务上的表现。三种 Configuration 的差异只能来自 Skill 的组织形式和关系信息呈现方式，不能来自任务、模型、Gold Standard、输出格式或评价规则的差异。

当前最终实验结构：

- 需要改变实验条件并实际重新运行：E0 完整 A/B/C 对比、E1 规模扩展、E4 精确/模糊描述、S1 相邻 Skill 边界干扰。
- 直接复用 E0 结果的分析：E2 约束任务分析、E3 任务复杂度分析、S2 No-Tool 分析、失败类型分析。
- 独立扩展实验：S3 父 Skill 识别与原子步骤展开。它不加入当前常规 Catalogue，因此不要求重跑 E0/E1。

- 当前已确认：
- 正式主任务集为 21 条，不含父 Workflow；原子 Skill 总数为 46。
 - Python evaluation 不读取全局关系 JSON，也不计算 Graph Validity Rate。
 - Configuration C 由 Codex 直接读取 Skill 描述和 `skill_relations.json`，自行寻找需要调用的 Skills 与顺序；Python 不负责路由或修正答案。
 - E1 固定任务改为 GT01、GT04、GT13、GT15、GT16；GT20 不再放入规模实验，而保留在专门的 No-Tool 分析中。
 - 第一轮每个条件先跑 1 次，用于排查配置、输出和 Gold 问题；时间充裕时再做 3 次重复实验。

2 数据与文件基础

2.1 当前任务与 Gold 结构

21 条任务分为五类：

类别	数量	任务范围与作用
单 Skill	1	GT01，检查最基础的 Skill 识别
单部门目标	5	GT02–GT06，分别覆盖财务、采购、技术、商务、人事
跨部门目标	9	GT07–GT15，覆盖 2–4 个部门和不同长度路径
特殊约束	3	GT16–GT18，覆盖冲突阻断和互斥路线
No-Tool	3	GT19–GT21，覆盖明显 No-Tool 与带业务关键词的迷惑性 No-Tool

Gold Standard 已包含：必要 Skill、可选 Skill、禁止 Skill、必要部门、任务级强制偏序、初始状态、任务级冲突或互斥规则、正确最终状态、阻断来源和路线选择。因此评价不要求 Codex 输出与某一条 canonical sequence 完全相同，只要求满足真正的硬约束。

2.2 46 个原子 Skills 的部门分布

部门	数量	Skills
Finance	8	预算制定、预算检查、费用申请、费用审核、发票核验、付款审批、账务处理、财务报表生成
Procurement	12	采购需求识别、供应商搜索、供应商资质检查、询价单生成、报价比较、供应商评分、供应商选择、合同生成、采购订单生成、交付跟踪、交付验收、供应商绩效评价
Technology	9	技术需求识别、技术规格确认、可行性评估、技术方案设计、任务拆解、开发或实施、技术测试验收、系统上线、运行维护
Business	9	客户线索管理、客户需求沟通、商机评估、方案与报价、商务谈判、合同签署、项目交付跟踪、业务验收、客户续约
HR	8	岗位需求、JD 生成、招聘发布、简历筛选、面试安排、Offer 生成、入职管理、员工数据库

3 三种 Configuration 的实验定义

3.1 Configuration A: Flat Catalogue（基线）

输入结构：将当前环境允许的所有 Skill 以同一级别展示，不提供部门分组，不提供显式前置、冲突、互斥或增强关系。

Codex 的工作：直接从平铺清单中识别相关 Skills，并自行推断部门、选择和顺序。

作用：A 是背景和 baseline，用来观察 Catalogue 扩大后，纯平铺目录是否更容易漏选、误选或排序错误。

3.2 Configuration B: Department-grouped Catalogue

输入结构：同一批 Skills 按 5 个部门分组，但不提供显式图边。每个 Skill 的名称与描述必须和 A 完全一致。

Codex 的工作：利用部门分组理解任务涉及的业务范围，再在相关部门中选择 Skills 和推断顺序。

作用：B 检验仅增加层级组织是否能改善部门选择、Skill 选择和稳定性。B 不应被预设为一**定**比 C 差；在简单单部门任务中，B 可能已经足够，且上下文更简单。

3.3 Configuration C: Graph-structured Catalogue

当前冻结实现：

- Codex 读取与 A/B 相同的 Skill 名称和功能描述；
- 额外读取 skill_relations.json；
- Codex 自己根据任务、当前状态和关系文件选择 Skill 并排列顺序；
- 不调用 Python 规划器，不让 Python 输出确定性路线；

- 关系 JSON 只属于 C 的路由输入，不进入 Gold-only evaluator。
关系语义必须在 C 的运行说明中明确：
- `contains`: 部门归属，不表示执行顺序；
- `prerequisite.before -> after`: 前置依赖，仅在相应 scope/condition 成立时启用；
- `conflict.skills[0]`: 产生检查结果的门槛 Skill；条件成立时阻止 `skills[1]`；
- `mutex`: 同一业务对象和同一轮决策只能选择一条路线；
- `enhances`: 可选质量增强，不是强制前置。

C 的优势来自“Codex 能看到显式关系”，而不是由外部程序替它规划。若 Python 直接返回最终路线，实验含义会变成“Python 规划器对比 Codex”，不再是 A/B/C 的 Skill 组织方式比较。

3.4 规模条件下 C 的闭合子图

在 E1 的 10、30、46-Skill 条件中，C 必须读取对应规模的裁剪关系文件，不能在 10-Skill 条件下仍看到完整 46-Skill 图。

裁剪是确定性的，因为所有关系都通过明确的 Skill ID 引用端点：

- `contains`: 只保留允许集合中的 children；
- `prerequisite`: before 与 after 都在允许集合中时保留；
- `conflict`、`mutex`: 其中所有 Skill 都在允许集合中时保留；
- `enhances`: source 与 target 都在允许集合中时保留。

裁剪后必须验证：节点数量与目标规模一致、没有清单外引用、10 是 30 的严格子集、30 是 46 的严格子集。本次配套脚本已经对附件关系文件实际生成并验证了三份闭合关系文件：

规模	部门记录	prerequisite	conflict	mutex	enhances	清单外引用
10	4	6	2	0	1	0
30	5	25	7	0	4	0
46	5	53	13	4	13	0

10-Skill 子图没有 mutex 边并不是错误：所选 10 个节点中没有完整保留任何一对互斥节点；GT13 的错误外部采购路线本身也不在 10-Skill Catalogue 中。

3.5 三种配置必须保持不变的控制变量

- 同一条任务 Prompt；同一模型、Codex 版本和推理设置；
- 同一批允许的 Skill 名称与描述；同一输出格式；
- 同一 Gold Standard 和 evaluator；
- 每条任务独立新会话，避免上下文污染；
- Codex 不得读取 Gold、evaluation 设计或标准答案；
- A/B/C 的唯一差异是 Skill 的组织与关系呈现方式。

4 实验总览与运行数量

实验/分析	条件与任务	完整观测数 (每轮)	复用 E0 后新增 输出
E0 完整对比	A/B/C, 46 Skills, 全部 21 题	63	63
E1 规模扩展	A/B/C, 10/30/46 Skills, 固定 5 题	45	30 (46-Skill 的 15 条复用 E0)
E2 约束分析	从 E0 抽取 9 条约束/长路径任务	27 条子集结果	0
E3 复杂度分析	从 E0 按类别、路径长度、部门数分组	63 条结果重新分组	0
E4 精确/模糊	A/B/C, 6 个代表任务, 各有精确与模糊版本	36	18
S1 相邻 Skill 干扰	A/B/C, 5 题, 正常目录与扩展目录	30	15
S2 No-Tool	从 E0 抽取 GT19–GT21	9 条子集结果	0
S3 父 Skill 扩展	A/B/C, 5 个父 Workflow 高层任务	15	15 (独立扩展)

第一轮立即建议先完成 E0 + E1, 共需新生成 93 个 JSON 输出 (63 + 30)。E4、S1 和 S3 都不阻塞第一轮。若 E0、E1、E4、S1、S3 全部完成, 每轮共需新生成 141 个输出。

5 E0: 完整 46-Skill A/B/C 主实验

5.1 目的与运行量

回答最核心问题: 在完整企业 Skill 环境中, 平铺、部门分组和图结构三种组织方式, 哪一种整体路由表现更好?

- 使用 GT01–GT21;
- A、B、C 各运行 21 条;
- 第一轮共 63 个输出; 每条任务独立运行并保存一个合法 JSON 对象。

5.2 主要指标

E0 主报告: Functional Success Rate、Clean Success Rate、Skill Precision/Recall/F1、Department F1、Required Order Accuracy、Gold Constraint Violation Rate、Final Status Accuracy、Route Choice Accuracy。

这些指标已经在当前 Python evaluator 的 per-task 或 summary 中实现。No-Tool 与 Blocked-Flow 的专门汇总见后文。

5.3 结果解释

- Functional Success 高：能完成业务目标，或在应阻断时正确停止；
- Clean Success 高：正确且没有多余 Skill、额外部门或重复步骤；
- Skill Recall 低：漏步骤；Skill Precision 低：多选无关步骤；
- Required Order Accuracy 低：选到了 Skill，但硬顺序错误；
- Gold Constraint Violation 高：违反任务级冲突、互斥、禁止项或状态规则；
- Department F1 低：部门路由本身存在问题。

6 E1：规模扩展实验（10 ⊂ 30 ⊂ 46）

6.1 目的

检验正常企业 Catalogue 扩大时，A/B/C 是否出现性能下降，以及哪一种组织方式更稳定。新增的是公司其他正常 Skills，而不是人为制造的近义干扰项。

6.2 固定 5 条任务（修订版）

任务 ID	选择原因
GT01	单 Skill 基础识别，观察目录扩大是否造成最简单任务误选
GT04	单部门中等长度路径，覆盖技术方案形成
GT13	技术 + HR，要求利用员工能力信息完成任务拆解
GT15	商务 + 采购，短跨部门链
GT16	供应商资质不合格后的阻断，检查是否停止并禁止后续 Skill

GT20 被移出 E1，因为 No-Tool 已由 S2 专门分析；E1 现在更集中地测量正常 Skill 路由、跨部门路径和阻断行为。

6.3 10-Skill 环境

固定 10 个 canonical Skill IDs：

1. procurement-supplier-qualification（供应商资质检查）
2. procurement-supplier-selection（供应商选择）
3. technology-feasibility-assessment（可行性评估）
4. technology-specification-confirmation（技术规格确认）
5. technology-solution-design（技术方案设计）
6. technology-task-breakdown（任务拆解）
7. hr-employee-database（员工数据库）
8. business-negotiation（商务谈判）

- 9. procurement-contract-generation (合同生成)
- 10. procurement-purchase-order (采购订单生成)

6.3.1 覆盖核对

任务	10-Skill 集合中的覆盖	结论
GT01	supplier qualification	完整
GT04	feasibility → specification → solution design → task breakdown	完整
GT13	GT04 技术链 + employee database, 并保持 employee database 在 task breakdown 前	完整
GT15	business negotiation → contract generation → purchase order	完整
GT16	qualification 是已知失败门槛; selection 与 contract generation 都保留为被禁止后续节点	完整

这 10 个 Skills 覆盖 5 条任务的全部必要 Skills、全部必要顺序，以及 GT16 的两个被阻断后续 Skill。10-Skill 环境没有 Finance Skill，也没有问题：规模实验首先要求正确路径完整与集合严格嵌套，而不是强制每个部门数量相等。

6.4 30-Skill 环境

30-Skill 环境必须包含上述全部 10 个 Skills，并扩展为每部门 6 个正常企业 Skills：

部门	6 个 Skills
Finance	预算制定、预算检查、费用申请、发票核验、付款审批、账务处理
Procurement	供应商搜索、供应商资质检查、供应商选择、合同生成、采购订单生成、交付跟踪
Technology	技术需求识别、可行性评估、技术规格确认、技术方案设计、任务拆解、技术测试验收
Business	客户线索管理、客户需求沟通、商机评估、方案与报价、商务谈判、合同签署
HR	岗位需求、JD 生成、简历筛选、Offer 生成、入职管理、员工数据库

6.5 46-Skill 环境

使用全部 46 个原子 Skills。46-Skill 条件下的 5 题结果直接从 E0 复用，不需要重复运行。

6.6 如何构造 A/B/C 的三个规模版本

- A：分别生成 10、30、46 的平铺清单；
- B：分别生成 10、30、46 的部门分组清单；

- C: 按规模分别读取配套包中的 10、30、46-Skill 关系文件; 只保留当前规模节点和两端都在集合内的关系;
- 同一 Skill 在三个规模中的 ID、名称和描述必须完全相同;
- 每次运行只能访问当前规模的文件, 不能同时访问完整主分支关系文件。

6.7 运行量与指标

完整条件数:

$$3 \text{ configurations} \times 3 \text{ sizes} \times 5 \text{ tasks} = 45.$$

46-Skill 的 15 条从 E0 复用, 因此 E0 之后新增 30 条输出。

主要使用已有指标: Functional Success、Clean Success、Skill F1、Department F1、Required Order Accuracy、Gold Constraint Violation Rate。真正关注的是性能下降幅度:

$$\text{Scale Drop}_{10 \rightarrow 46} = \text{Score}_{46} - \text{Score}_{10}.$$

Scale Drop 是汇总阶段的派生统计, 当前 evaluator 不直接输出, 不需要改变逐题评分逻辑。

7 E2: 约束任务分析 (复用 E0, 不重新运行)

建议从 E0 抽取 GT07、GT08、GT09、GT10、GT12、GT13、GT16、GT17、GT18。

使用: Required Order Accuracy、Gold Constraint Violation Rate、Functional Success、Route Choice Correct、Blocked-Flow Correct (GT16–GT17), 并统计以下失败标签:

- ORDER_VIOLATION、MUTEX_VIOLATION、CONFLICT_VIOLATION;
- WRONG_ROUTE_CHOICE、CONTINUE_AFTER_BLOCK。

当前 aggregate 不会自动生成这 9 题的专门表, 需要从 per-task CSV 按 task ID 过滤并汇总。

8 E3: 任务复杂度与组织方式分析 (复用 E0)

旧的“只比较 B 与 C”不再单独作为实验。更合理的问题是: A/B/C 的差距是否随任务复杂度变化?

8.1 按现有任务类别分组

当前 evaluator 已生成 summary_by_category.csv, 可直接比较五类: 单 Skill、单部门目标、跨部门目标、特殊约束和 No-Tool。

8.2 按 Gold 路径长度分组

可按 required skill count 分为: 短路径 0–3、中路径 4–6、长路径 7 个及以上。当前 evaluator 不自动生成该分组, 需要后处理。

8.3 按必要部门数量分组

比较 0、1、2、3、4 个部门的任务表现。当前 per-task 没有直接保存 required department count，需要从 Gold 合并或增加简单输出字段；这不是第一轮评分的阻塞项。

9 E4：精确描述与模糊描述

选择 GT03、GT04、GT07、GT11、GT16、GT18，为每题制作一个仍然可解、但表达更间接的模糊版本。精确版本复用 E0，因此只新增：

$$6 \text{ vague prompts} \times 3 \text{ configurations} = 18 \text{ outputs.}$$

使用现有 Functional Success、Skill F1、Department F1、Required Order Accuracy、Gold Constraint Violation Rate；派生统计为：

$$\text{Ambiguity Drop} = \text{Score}_{\text{vague}} - \text{Score}_{\text{precise}}.$$

模糊 Prompt 尚未创建，本指南不展开具体文本。

10 S1：相邻 Skill 边界干扰实验（可选补充）

该实验加入现实中可能存在、主题相近但职责不同的相邻 Skill，而不是完全无关项。建议固定 5 题，比较原始 46 Skills 与 46 + 6–8 个相邻职责 Skills；原始条件复用 E0，只新增 15 个输出。

若新增 Skill 不写入 S1 专用 Gold catalog，当前 evaluator 会判为 UNKNOWN_SKILL。因此正式做 S1 时应复制专用 Gold、把新增项加入 catalog，但保持 required Skills 不变，使误选被计入 extra Skills。Distractor Selection Rate 暂未实现，也不阻塞第一轮。

11 S2：No-Tool Detection（复用 E0）

使用 GT19–GT21：明显闲聊、带“预算检查”关键词的概念解释、带采购关键词的玩笑。

当前 evaluator 每题输出 no_tool_correct，但 summary 不直接输出名为 No-Tool Accuracy 的列。可筛选这 3 题后平均 no_tool_correct，或平均其 Functional Success。样本只有 3 条，只适合作为基础稳健性检查。

12 S3：父 Skill 识别与原子步骤展开（独立扩展）

12.1 为什么作为独立扩展

父 Skills 不加入当前 A/B/C 常规 Catalogue，而在单独实验中同时提供父 Skills 与全部原子 Skills。这样仍然可以测试：系统能否先理解高层目标、选对父流程，再展开成完整原子步骤；同时不改变当前 46-Skill 主实验，也不需要重跑 E0/E1。

12.2 父 Skill 的定义

父 Skill 不是可直接执行的动作，而是一个高层业务目标或 workflow container。建议先设计 5 个：

建议 ID (待最终冻结)	中文 display name	主要展开方向
finance-processing-workflow	财务处理流程	预算、费用、发票、付款、入账、报表
supplier-procurement-workflow	供应商采购流程	需求、预算、供应商、合同、订单、交付
technology-development-workflow	技术开发流程	需求、可行性、规格、方案、开发、测试、上线
customer-business-workflow	客户业务流程	线索、需求、商机、报价、谈判、签约、验收、续约
recruitment-onboarding-workflow	招聘与入职流程	岗位、预算、发布、筛选、面试、Offer、入职、归档

这些 ID 只是设计建议；正式创建时应与 main 分支的英文命名规范统一。

12.3 A/B/C 在扩展实验中的输入

- A-parent: 5 个父 Skills 与 46 个原子 Skills 同级平铺；
- B-parent: 按部门/流程分组，父 Skill 位于对应组顶部，子 Skills 在组内；
- C-parent: 在现有关系图上增加父子 contains 或 expands_to 关系，并保留原有前置、冲突、互斥与增强关系。

三种条件都必须看到相同的父 Skills、相同的原子 Skills 和相同的功能描述；差异仍然只是组织与关系呈现。

12.4 任务与运行量

第一版可为 5 个父 Workflow 各设计 1 条高层任务，共 5 条；A/B/C 各运行 5 条：

$$5 \text{ tasks} \times 3 \text{ configurations} = 15 \text{ outputs.}$$

后续若要更深入，可再加入阻断、分支和跨部门父流程任务，但不必影响主实验。

12.5 评价器需要的小型扩展

当前 V4 evaluator 只评价原子 Skill sequence，不知道“父 Skill 是否被正确识别”。S3 运行前建议使用独立 schema/Gold，增加：

- selected_parent_skills: 选择的父 Skill；
- expanded_skill_sequence: 展开后的原子 Skill 顺序。

新指标：Parent Skill Identification Accuracy、Parent-only Failure Rate。已有逻辑可复用：原子 Skill Precision/Recall/F1、Required Order Accuracy、Route Choice Accuracy、

Blocked-Flow Accuracy。Expansion Completeness 可直接解释为原子 Skill Recall，不必重复发明一个完全相同的评分公式。

S3 的结论是“系统具备父流程识别与展开能力”。只有当未来想研究“父 Skills 加入日常 Catalogue 后是否整体改善或干扰所有普通任务”时，才需要把父 Skills 加入常规 A/B/C 并重新跑主实验。

13 评价指标与当前 Python 实现对照

指标/字段	每题	Summary	使用方式与后续工作
Functional Success	已实现	已实现	E0 主指标；其余实验通用
Clean Success	已实现	已实现	正确且无多余调用
Skill Precision/Recall/F1	已实现	已实现	所有主实验通用；S3 的原子展开也可复用
Department Precision/Recall/F1	已实现	F1 已有	Precision/Recall 需要时另行汇总
Required Order Accuracy	已实现	已实现	约束、长路径和父 Skill 展开的核心指标
Gold Constraint Violation Rate	已实现	已实现	任务级硬约束违规比例
Final Status Correct	已实现	已实现	completed/blocked/no_tool
Route Choice Correct	已实现	已实现	互斥路线和验收路线
No-Tool Accuracy	已实现	未专门汇总	筛选 GT19-GT21 后平均
Blocked-Flow Accuracy	已实现	未专门汇总	筛选 GT16-GT17 后平均
Failure Tags	已实现	部分	指定子集需后处理
Scale Drop	未实现	未实现	E1 根据 10/30/46 summary 差值计算
Ambiguity Drop	未实现	未实现	E4 根据 vague/precise 差值计算
Distractor Selection Rate	未实现	未实现	S1 可选扩展
Parent Identification Accuracy	未实现	未实现	S3 独立 evaluator/schema 新增
Parent-only Failure Rate	未实现	未实现	S3 判断只选父 Skill、未展开原子步骤
重复运行均值	已实现	已实现	aggregate 可跨 run 取平均
重复运行标准差/一致性	未实现	未实现	3 次重复后建议后处理

14 真实运行流程

14.1 运行前冻结清单

1. 确认最终 Prompt 是最新版，包含三种合法 JSON 状态示例；
2. 冻结 A/B/C 的 46-Skill 输入；C 固定为 Codex 直接读取 `skill_relations.json`；
3. 为 E1 生成 A/B 的 10/30 清单和 C 的 10/30 闭合关系文件；
4. 记录 Git commit、模型/Codex 版本、运行日期、run ID；
5. 运行 package validation，确认 Gold valid=true；
6. 检查实验会话只能访问当前 Configuration 和当前规模的文件。

14.2 单条任务运行规则

1. 新建干净会话；
2. 只让 Codex 读取当前 Configuration/规模允许的 Skill 文件和该条任务 Prompt；
3. 不提供 Gold、review、evaluation 说明；
4. Codex 只输出一个合法 JSON；
5. 原样保存，不人工修正；
6. 结束后清空上下文，再运行下一条。

14.3 建议保存目录

```
predictions/  
  E0_full46/  
    A/run_01/GT01.json ... GT21.json  
    B/run_01/GT01.json ... GT21.json  
    C/run_01/GT01.json ... GT21.json  
  E1_scale/  
    size_10/A|B|C/run_01/  
    size_30/A|B|C/run_01/  
    size_46/    # reuse E0  
  S3_parent_extension/  
    A|B|C/run_01/
```

实验名称、catalogue size、prompt variant 等条件信息应放在目录或 manifest 中，不要强行加入 Codex 固定输出 JSON，以免改变现有 schema。

15 第一轮跑一次与三次重复的区别

15.1 第一轮先跑一次

第一轮用于检查：A/B/C 是否只有组织方式不同、Codex 是否稳定输出合法 JSON、Skill/部门 ID 是否一致、Gold 是否遗漏合法替代路径、C 是否过度提示或上下文过重、整套运行耗时是

否可接受。

因此第一轮先完成 E0 + E1 的 93 个新输出，并人工复核失败案例。

15.2 时间充裕时跑三次

LLM 路由可能因采样、上下文处理或服务端变化而波动。三次重复可以降低偶然结果影响、计算平均表现、比较路线稳定性，并识别“平均分接近但波动不同”的配置。

建议补充：每个指标的 mean 与 standard deviation、每题 3-run consistency rate、三次中至少成功 2 次的 majority success。若资源有限，可优先重复 E0、E1，以及复杂跨部门和特殊约束任务。

16 结果解读与避免误判

- 不只看 Functional Success；同时看 Clean Success 与 Skill Precision；
- 不只看 Skill F1；顺序错误仍会导致流程失败，应结合 Required Order Accuracy；
- 不预设 C 一定最好；图关系可能帮助复杂任务，也可能增加简单任务的上下文负担；
- E2/E3/S2 是 E0 的重新切片，不是重复实验；
- E1 的 10-Skill 集合是任务覆盖驱动，不要求五部门平均；
- S3 是独立能力测试，不与当前 46-Skill 主实验混在一起解释；
- 若 Gold 有遗漏，应修 Gold 并重跑所有受影响条件，不能只修某一个 Configuration 的结果。

17 下一步开始跑之前的待办清单

状态	项目	说明
✓	最终 21 条 Prompt	确认实际 repo 使用最新版
✓	V4 Gold-only evaluator	足以完成 E0/E1 核心评分
✓	Configuration C 运行边界	Codex 直接读取 Skill 描述和关系 JSON，自行路由；无 Python planner
✓	E1 任务与 10-Skill 集合	已改为 GT01/04/13/15/16，覆盖验证完成
✓	C 的规模关系文件	配套脚本已生成并验证 10/30/46 闭合关系文件
●	A/B 的 10/30/46 输入	依据同一 manifest 生成平铺和部门分组版本
●	C relation semantics 提示	正式运行说明中明确 contains/prerequisite/conflict/mutex/enhances 语义
☒	E4 模糊 Prompt	后续创建，不阻塞 E0/E1
☒	S1 相邻 Skills 与专用 Gold	后续创建，不阻塞 E0/E1
☒	S3 父 Skills 与扩展 evaluator	独立扩展，主实验完成后再创建

推荐实际顺序：

1. 用 E1 manifest 生成 A/B 的 10/30 输入，并使用已生成的 C 关系文件；
2. 运行一次 E0；检查格式、失败案例和 Gold；
3. 运行 E1 的 10/30 条件；完成 Scale Drop 和 E2/E3/S2 子集分析；
4. 再决定是否制作 E4、S1；
5. 主实验稳定后，单独创建 S3 父 Skills、5 条高层任务与扩展评价器。

A Run Guide v1.1 相对 v1.0 的修订

- E1 将 GT20 替换为 GT16；
- 10-Skill 集合删除预算检查，加入供应商选择；
- 30-Skill 集合同步调整，确保 $10 \subset 30 \subset 46$ ；
- 明确 Configuration C 的当前最终方式：Codex 直接读取 `skill_relations.json`，无 Python 路由；
- 增加 C 的关系裁剪规则、实际验证结果和配套脚本说明；
- 新增 S3 父 Skill 独立扩展实验，并说明所需 schema/metric 增量；
- 更新实验运行总量、待办清单和推荐执行顺序。

B 配套可下载文件

本指南配套：

- `E1_scale_manifest.json`：E1 的任务、10-Skill 与 30-Skill 集合；
- `build_scaled_relations.py`：从完整关系文件生成闭合的 10/30/46 关系文件；
- 三份裁剪关系文件：10-Skill、30-Skill、46-Skill；
- `scale_relations_validation_report.json`：节点、关系数量和清单外引用检查；
- 本 PDF 与变更说明。

资料依据与版本说明

本指南以 Run Guide v1.0、V4 Gold Tasks、最终 Prompt、V4 Gold-only evaluator 设计和当前 `skill_relations.json` 为基础修订。父 Skill 的英文 ID 仍属于设计建议，正式创建时应按照 main 分支命名规范冻结。